

Topic modelling and dimensionality reduction

masha.shejanova@gmail.com

Тематическое моделирование

Что и зачем

Тема — “о чём документ” \approx набор часто совместно встречающихся слов

Мы считаем, что тема употребление того или иного слова зависит от темы. А тема — от документа.

Зачем:

- поиск в электронных библиотеках
- трекинг новостных сюжетов
- “продвинутый” эмбединг документа

Базовое предположение

- каждый **документ** состоит из смеси некоторых **тем** (*topics*)
- каждая **тема** состоит из набора **слов**

Иными словами, темы — это скрытые (латентные) переменные, которые управляют распределением слов в документе.

topic modeling vs. clustering



Что похожего: есть документы, раскидываем их по кучкам, заранее не знаем по каким.

Что разного: у одного документа может быть высокая степень принадлежности больше, чем к одной теме.

РСА (метод главных компонент): идея

Базис линейного пространства

Стандартный базис:



Замена базиса

На самом деле, базисные вектора можно выбирать как угодно — главное чтобы можно было выразить через них все вектора пространства.

(И чтобы сами базисные вектора нельзя было выразить друг через друга).





Figure 1: Vector combinations.

РСА

Найдём такой базис, чтобы как можно лучше выразить как можно больше значений за счёт фиксированного количества базисных векторов.

Сделаем проекцию всех данных на эти вектора.



SVD (сингулярное разложение):
реализация


SVD

Любую матрицу M можно разложить на произведение трёх матриц: $M = U \cdot \Sigma \cdot V^*$

U, V^* — матрицы поворота

Σ — матрица растяжения

У Σ числа стоят только на главной диагонали, причём они убывают




$$M = U \cdot \Sigma \cdot V^*$$

Truncated SVD

$$A \approx U_t S_t V_t^T$$

Intuitively, think of this as only keeping the t most significant dimensions in our transformed space.




(скрин из [ВОТ](#)
[ЭТОЙ](#) статьи)

Truncated SVD
= LSA (latent
semantic
analysis) in topic
modeling


Разделение документов по темам

(ИСТОЧНИК)



1. Строим матрицу как часто каждое слово встречается в каждом документе
(чернее - чаще)

→
SVD
2. Раскладываем



3. Получаем наглядные кластера по тематикам
(даже если слова не встречались вместе)

Латентно-семантический Анализ (LSA)

На собачках

Full-Rank Dog



Rank 200 Dog



Rank 30 Dog



Rank 20 Dog



При большом
количестве компонент
разница незаметна.

([ИСТОЧНИК](#))

Rank 100 Dog




Rank 50 Dog



Rank 10 Dog



Rank 3 Dog



pLSA: probabilistic LSA


Probabilistic Latent Semantic Analysis

- использует вероятности
- генеративная

Два предположения:

- **документ** состоит из смеси некоторых **тем** → topic **z** is present in that document **d** with probability **$P(z|d)$**
- каждая **тема** состоит из набора **слов** → given a topic **z**, word **w** is drawn from **z** with probability **$P(w|z)$**


Probabilistic Latent Semantic Analysis




$$P(D, W) = P(D) \sum_Z P(Z|D) P(W|Z)$$

pLSA vs. SVD

- Start with document



- Start with topic



$$P(D, W) = \sum_Z \underbrace{P(Z)}_{\text{purple}} \underbrace{P(D|Z)}_{\text{red}} \underbrace{P(W|Z)}_{\text{blue}}$$

$$A \approx \underbrace{U_t}_{\text{red}} \underbrace{S_t}_{\text{blue}} \underbrace{V_t^T}_{\text{purple}}$$

The diagram illustrates the relationship between the joint probability distribution $P(D, W)$ and the matrix factorization $A \approx U_t S_t V_t^T$. In the equation above, the terms are color-coded to match the arrows in the diagram below: $P(Z)$ is purple, $P(D|Z)$ is red, and $P(W|Z)$ is blue. Similarly, in the matrix factorization, U_t is red, S_t is blue, and V_t^T is purple. Three colored arrows (purple, red, and blue) point from the underlined terms in the equation above to the corresponding terms in the equation below.

Что ещё бывает? (Более продвинутые вещи)

- LDA (a Bayesian version of pLSA, использует распределение дирихле)
- ARTM — LDA, но с регуляризацией
- bigARTM — ARTM с наворотами :) (но вообще, это библиотека, в которой есть все эти методы и больше!)

Снижение размерности

Что и зачем

В общем случае — у нас есть признаковое пространство на много-много измерений (например, мешок слов по корпусу, и каждое слово — признак). Мы хотим “сжать” их как-то так, чтобы потерять минимум информации.

Каждое новое “измерение” — элемент вектора — будут заключать в себе обобщённое представление нескольких элементов из большого вектора.

- убрать несущественные признаки
- тематическое моделирование
- визуализация

SVD

LSA == PCA == Truncated SVD

t-SNE


- используется для визуализации
- хорош только для перевода в очень маленькие размерности

Шаги:

- посчитать расстояние от каждой точки до каждой другой (используя формулу нормального (SNE) или Т распределения (t-SNE))
- случайно породить соответствующие им точки в маленькой размерности
- решить задачу оптимизации: надо, чтобы распределения расстояний (реальных и в пространстве маленькой размерности) максимально совпадали

t-SNE

Now we calculate the “unscaled similarity” for this pair of points.



At each step, a point on the line is attracted to points it is near in the scatter plot, and repelled by points it is far from...

