Нейросети. Эмбеддинги слов. WMD.

Маша Шеянова, masha.shejanova@gmail.com

Как устроена нейросеть

нейросеть in a nutshell

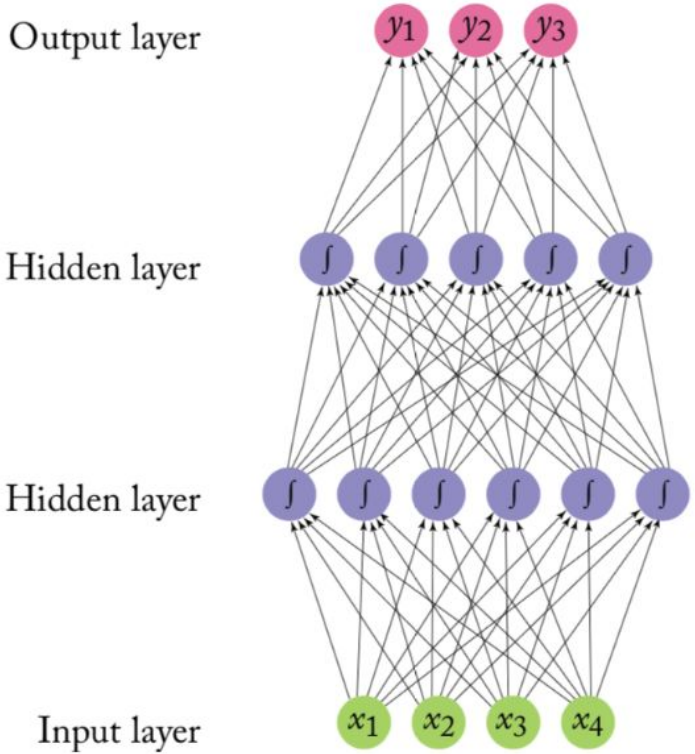

На входе — вектор признаков.

На каждой стрелочке — какие-то коэффициенты.

На выходе — вектор вероятностей того или иного класса.

“Нейрон” == один кружочек == функция от выдачи предыдущего слоя.

Нейросеть как функция

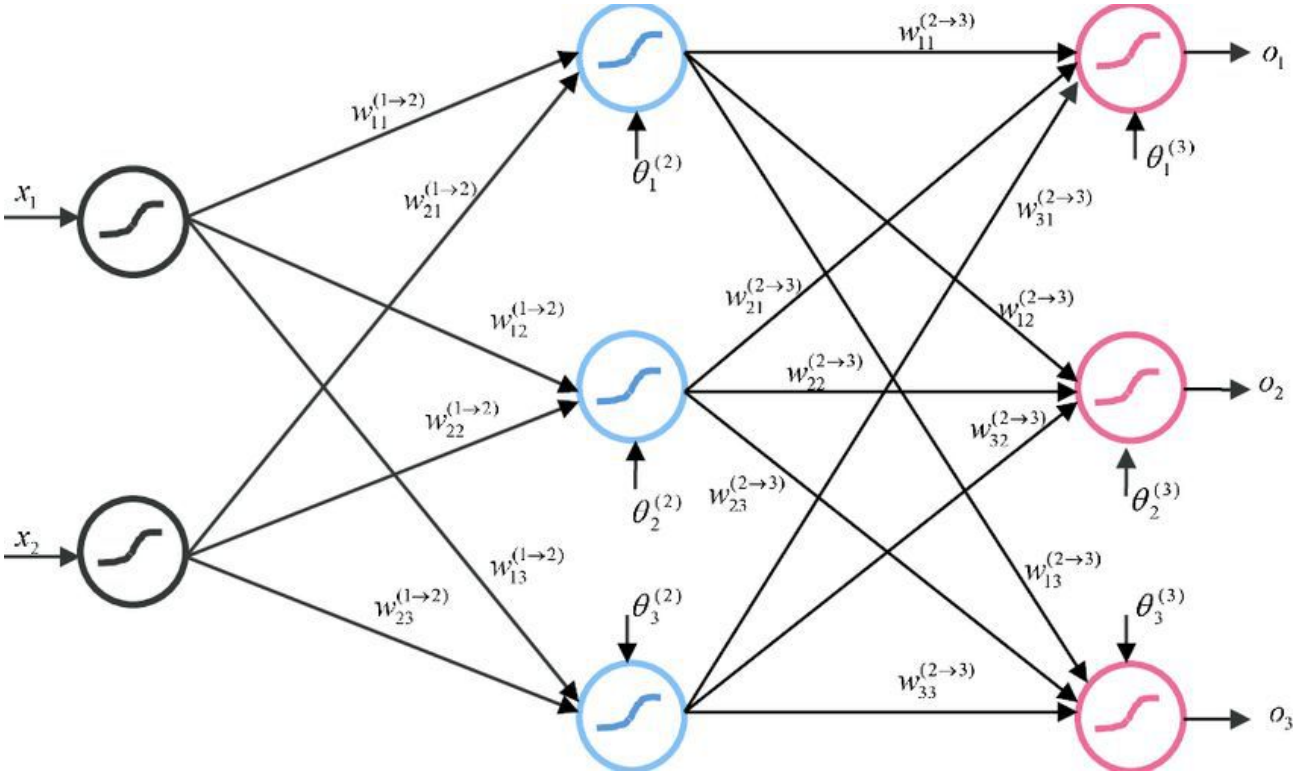

Один нейрон — функция от **вектора** параметров (w_{11}, w_{21}), умноженного на **вектор** объекта x (+ b).
*f(**wx** + b)*

Слой — функция от **матрицы** параметров * x + **вектор** b.
*f(**Wx** + **b**).*

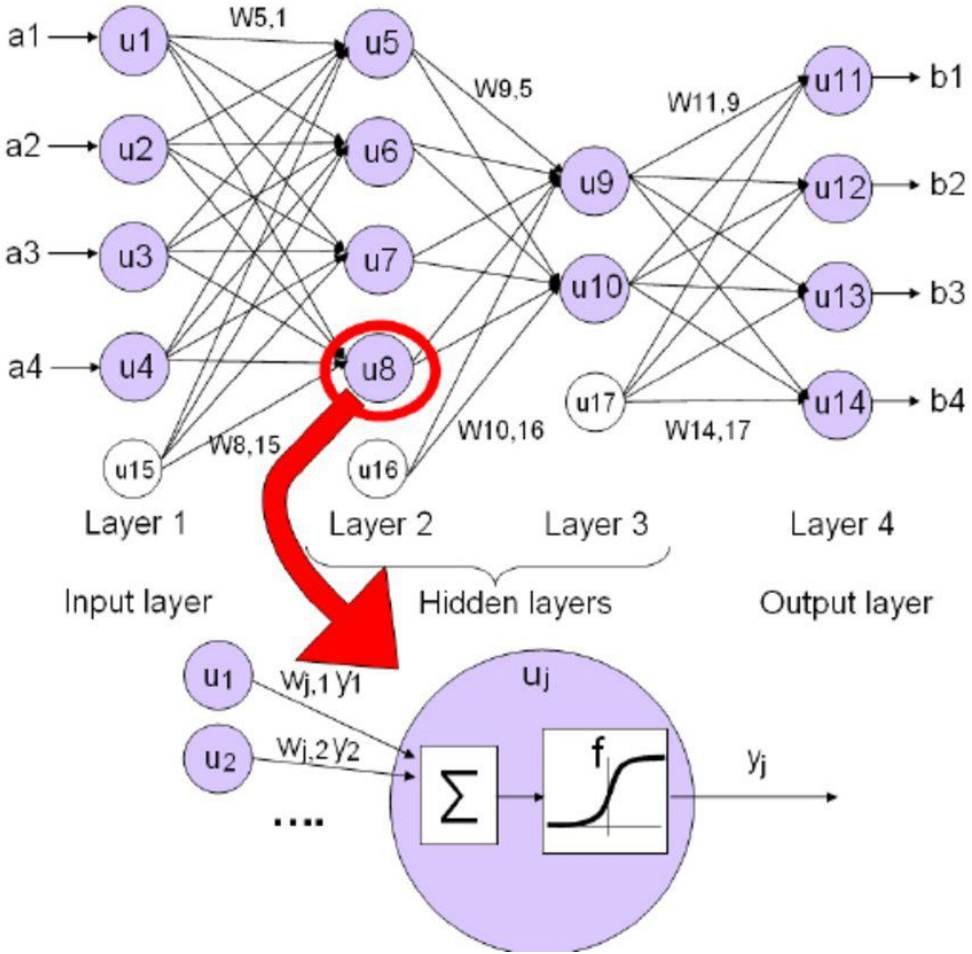

Четырёхслойная нейросеть.

Универсальная теорема аппроксимации: любую функцию можно приблизить нейросетью.

Функции активации

Почему “функция активации”?

… по аналогии с естественными нейросетями.

Справа — “step function”: нейрон активировался (1) или нет (0). (Источник картинки)

Но для artificial NN нужно что-то дифференцируемое.

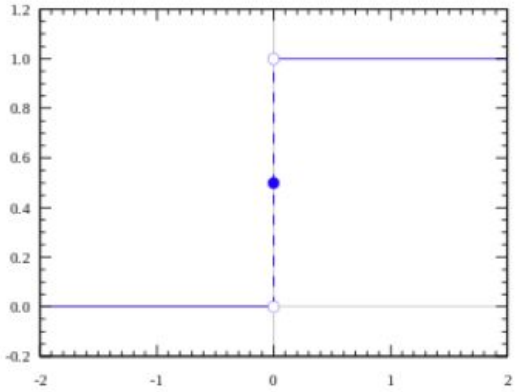

Почти все картинки этого раздела взяты отсюда.

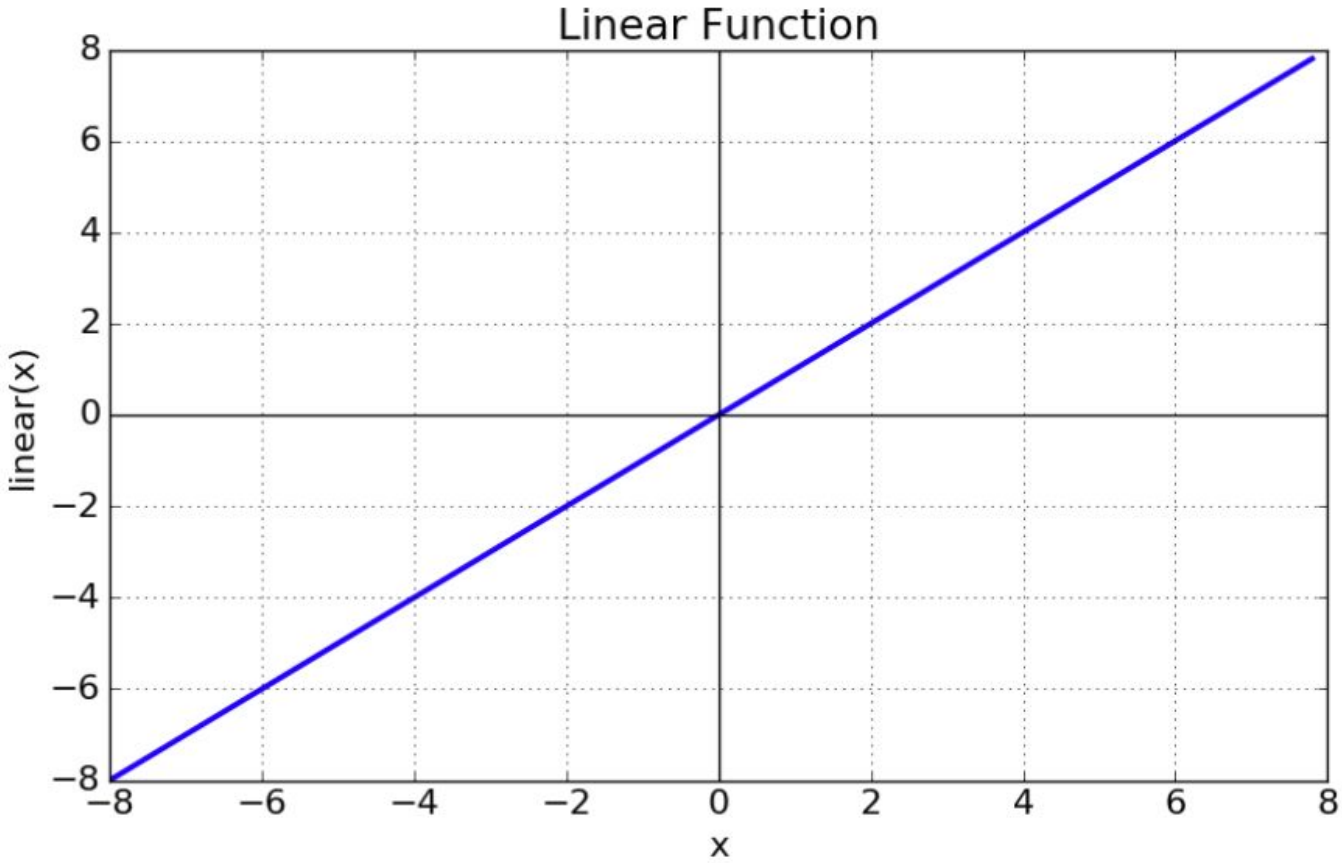

Fig: Linear Activation Function

Sigmoid function

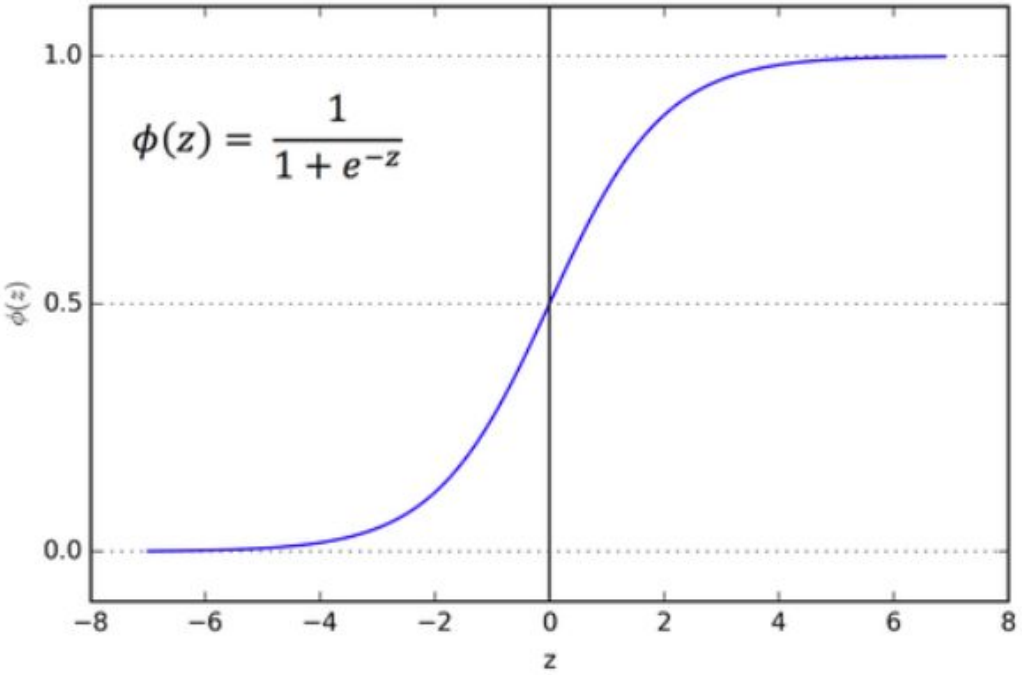

Это то же самое, что и логистическая регрессия.

Изменяется от 0 до 1 (и поэтому — хороший выбор для выдачи вероятностей).

Tanh or hyperbolic tangent Activation Function

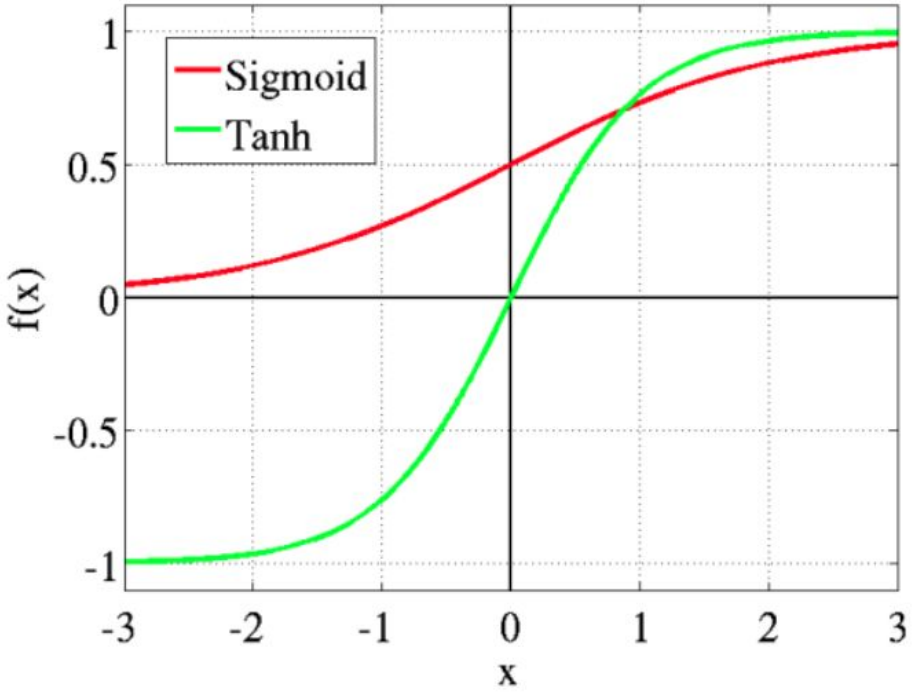

Похожа на предыдущую, но изменяется от -1 до 1.

ReLU и Leaky ReLU

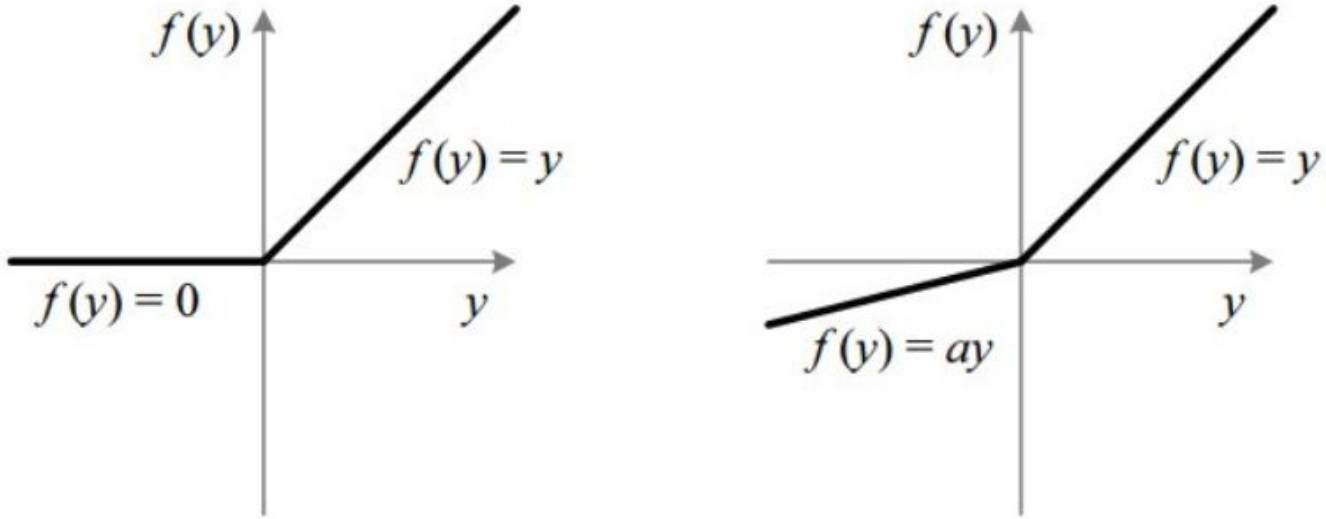

Fig : ReLU v/s Leaky ReLU

Backpropagation

Градиентный спуск

Производная

Производная — это мера, насколько быстро растёт функция.

$$f'(x_0) = \lim_{\Delta x \to 0} \frac{\Delta f}{\Delta x}$$

У функции от n переменных f(x1, x2, ... x_n) нет одной общей производной — зато есть n частные производные.

$$\frac{\partial f}{\partial x_k}(a_1, \cdots, a_n) = \lim_{\Delta x \to 0} \frac{f(a_1, \ldots, a_k + \Delta x, \ldots, a_n) - f(a_1, \ldots, a_k, \ldots, a_n)}{\Delta x}$$

Что такое градиент

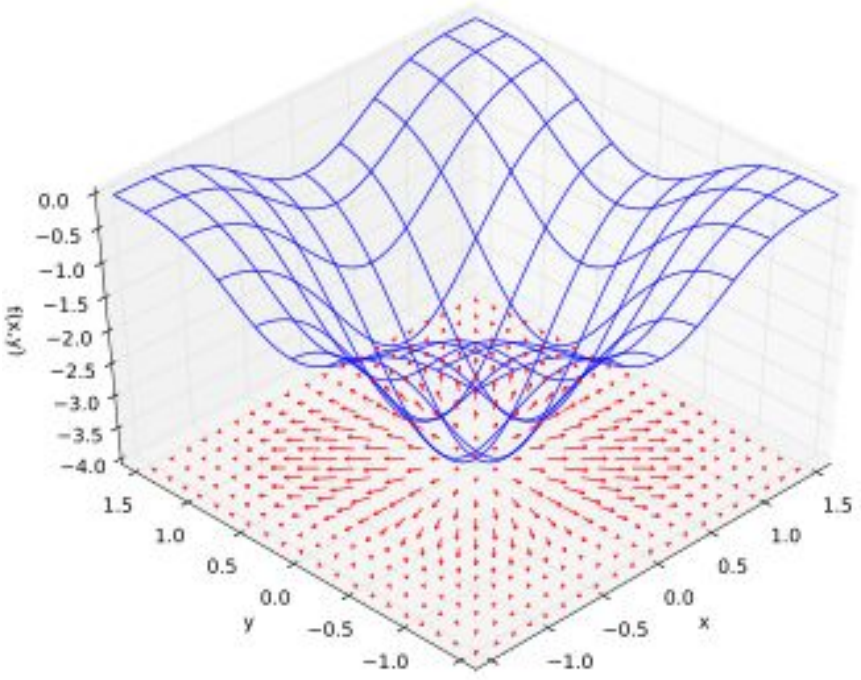

Градиент — это вектор, элементы которого — значения всех возможных частных производных в конкретной точке.

Градиент соответствует вектору, указывающему направление наибольшего роста функции.

Идея

loss function = cost function = error function = функция потерь = J(W)

Её мы хотим минимизировать.

Теперь мы умеем находить, в каком направлении функция растёт быстрее всего. Но нам нужен минимум функции потерь, а не максимум!

Решение очевидно: найдём градиент и пойдём в обратную сторону.

С какой скоростью? Растёт быстро — с большой, медленно — с маленькой.

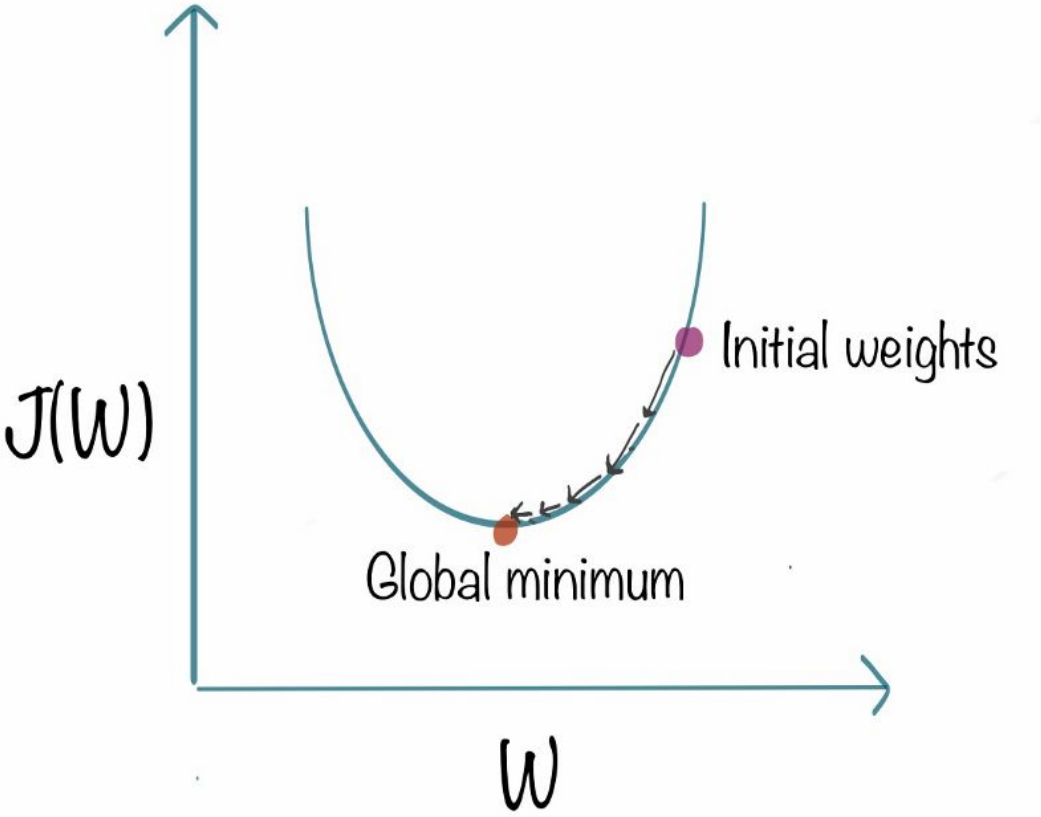

Источник картинки — очень понятно про то, как оно работает и какое бывает.

Шаги:

- подобрать случайные коэффициенты
- вычислить градиент функции потерь в этой точке
- обновить коэффициенты
- повторять, пока не сойдётся

Шаг градиентного спуска формулой

$$\mathbf{x}_{n+1} = \mathbf{x}_n - \gamma_n \nabla F(\mathbf{x}_n),\ n \geq 0.$$

x — вектор параметров (весов)

n — номер шага

гамма — learning rate

$F(x_n)$ — функция потерь, когда у нейросетки были параметры x_n (то есть обычно усреднённое значение на некотором количестве данных)

$\nabla F(x_n)$ — градиент (вектор частных производных) функции потерь в этой точке

Learning rate

$$\theta_1 := \theta_1 - \alpha \frac{\partial}{\partial \theta_1} J(\theta_1)$$

If α is too small, gradient descent can be slow.

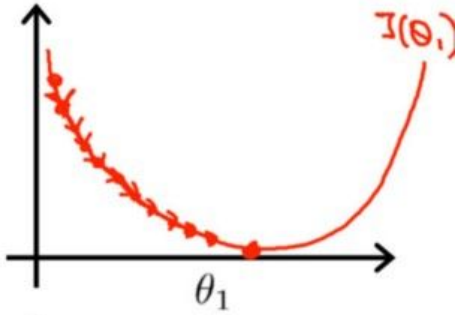

If α is too large, gradient descent can overshoot the minimum. It may fail to converge, or even diverge.

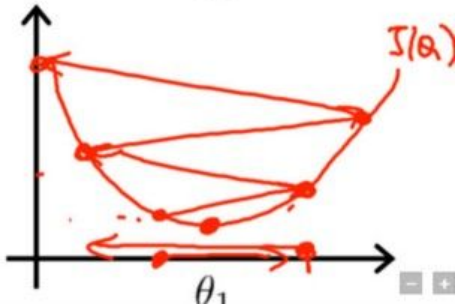

Learning rate is a hyper-parameter that controls how much we are adjusting the weights of our network with respect the loss gradient. (отсюда)

Каким бывает градиентный спуск

- **Batch gradient descent**

  Считает градиент функции потерь с параметрами W сразу для всех обучающих данных. Работает жутко медленно.

- **Stochastic gradient descent (SGD)**

  Рандомно выбирает точку данных каждый раз

- **Mini-batch gradient descent**

  Выбираем кусочек выборки и по нему считаем

Что делать, если всё ещё ничего непонятно

Непонимание градиентного спуска, в принципе, не помешает вам решать типичные задачи готовыми инструментами. Но может помешать улучшать модель и решать проблемы, если что-то пойдет не так.

Если всё ещё ничего непонятно, keep calm and:

- пройдите небольшой курс по multivariate calculus на khan academy
- посмотрите вот это видео про градиентный спуск
- прочитайте эту и эту статью
- если удастся сформулировать вопросы, спрашивайте :)

Интуиция за backpropagation

Функция потерь

Она может быть разной, **например** так:

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2$$

MSE в виде кода:

```
L = ((y_true - y_pred) ** 2).mean()
```

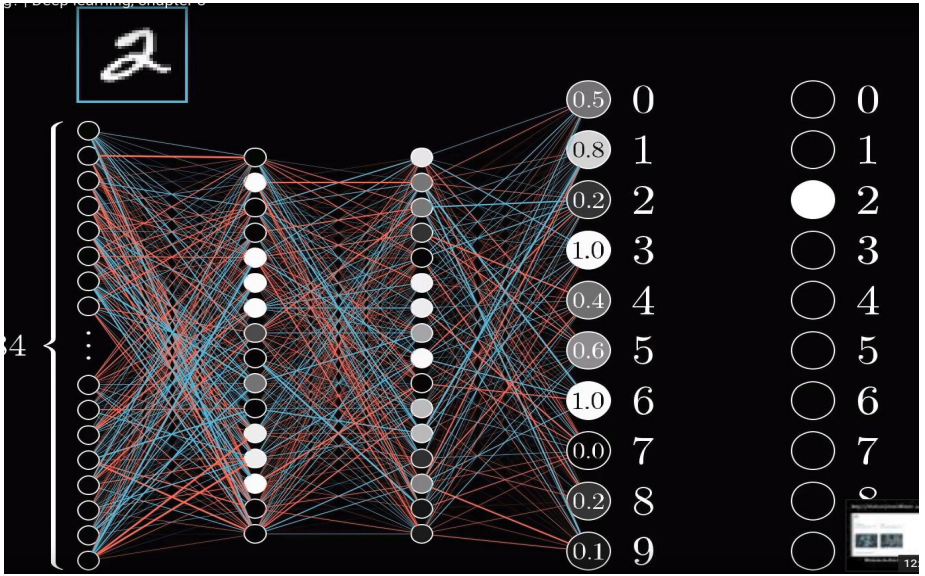

Суммирование ошибки

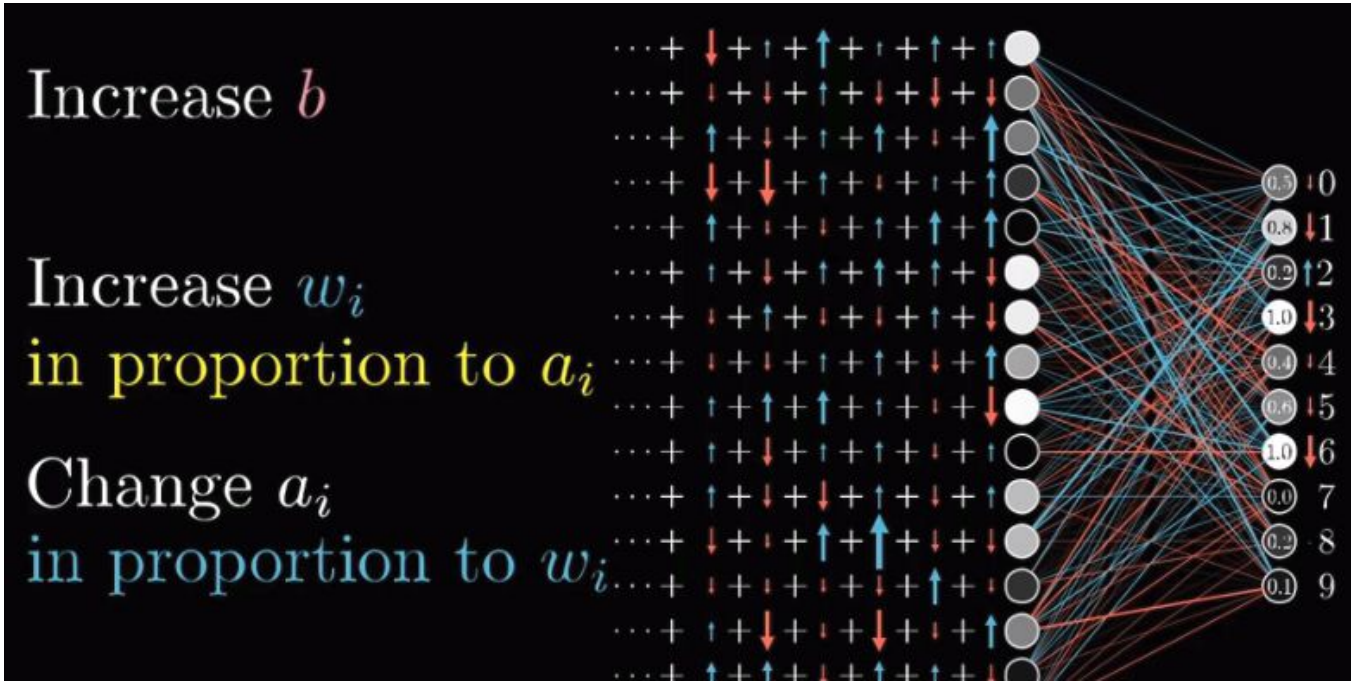

А дальше минимизируем функцию потерь.

Каждый объект говорит о том, как надо изменить веса, чтобы стало “правильнее”.

Обратное распространение

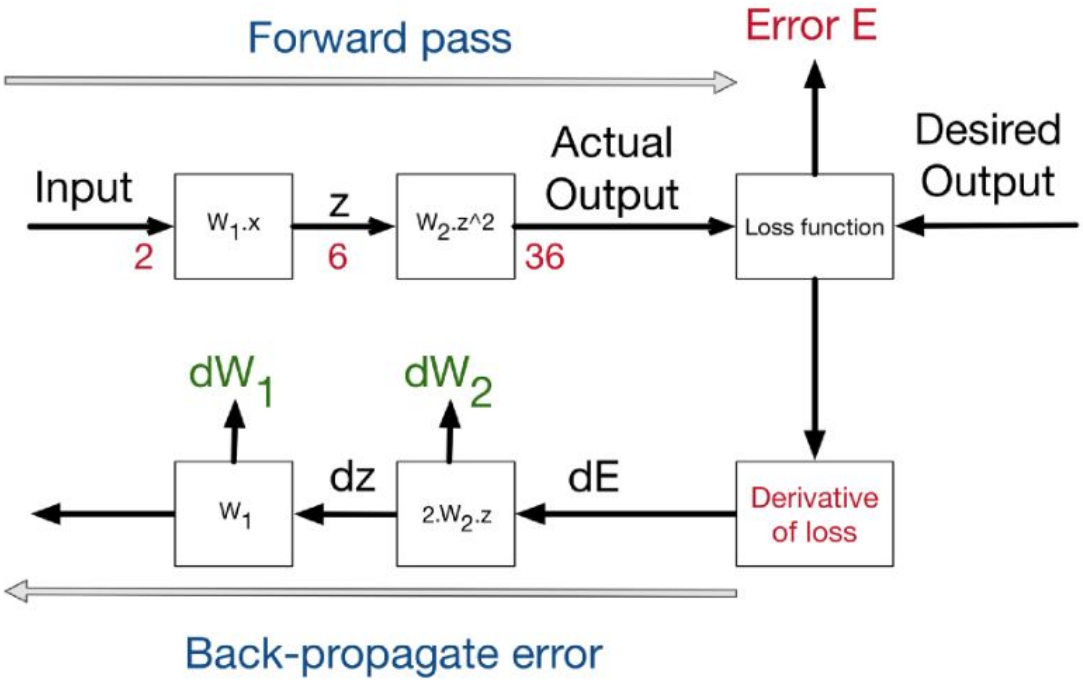

- слой за слоем применяем нейронку
- предсказываем класс объекта
- сравниваем с реальным и считаем ошибку
- слой за слоем изменяем параметры

Теория за backpropagation

Нейросеть — это тоже функция

x — входные данные (признаки); W — веса

$h_1 = f_1(W_1 * x + b_1)$

$h_2 = f_2(W_2 * h_1 + b_2)$

$y\_pred = f_3(W_3 * h_2 + b_3)$

$y\_pred = f_3(W_3 * f_2(W_2 * h_1 + b_2) + b_3)$

$loss = ((\mathbf{y\_pred} - \mathbf{y\_true})^2).mean()$

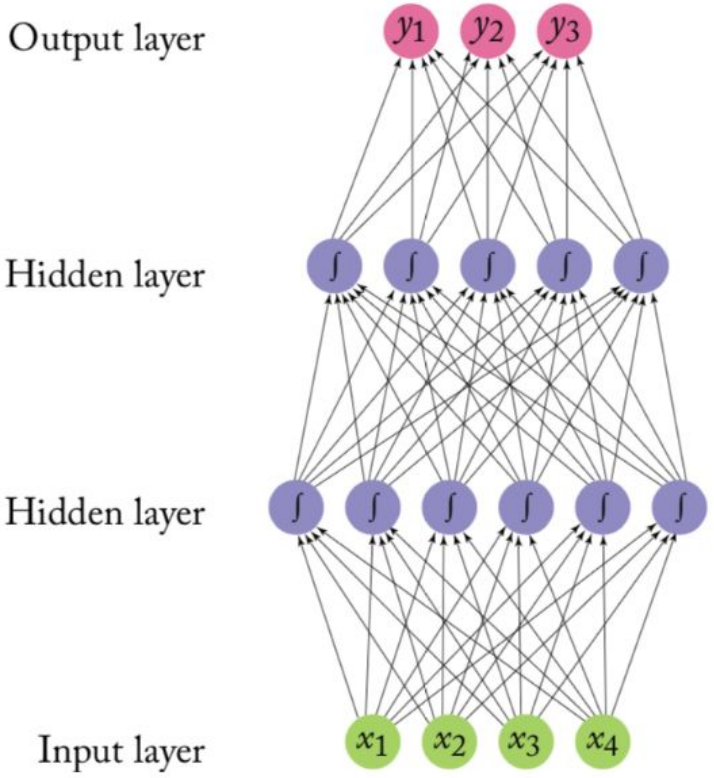

Композиция функций

В математике:

Substituting a function or it's value into **another** function.

Second

$$f\left(g\left(x\right)\right)$$

First

(inside parentheses always first)

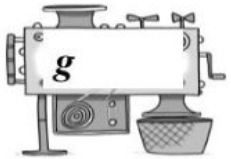

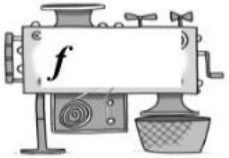

OR

$$f \circ g\left(x\right)$$

В программировании — то же самое!

Chain Rule

Это правило про то, как брать производную от композиции функций.

$$(f \circ g)' = (f' \circ g) \cdot g'.$$

This may equivalently be expressed in terms of the variable. Let $F = f \circ g$, or equivalently, $F(x) = f(g(x))$ for all x. Then one can also write

$$F'(x) = f'(g(x))g'(x).$$

Эмбеддинги

Как найти, насколько близки слова?

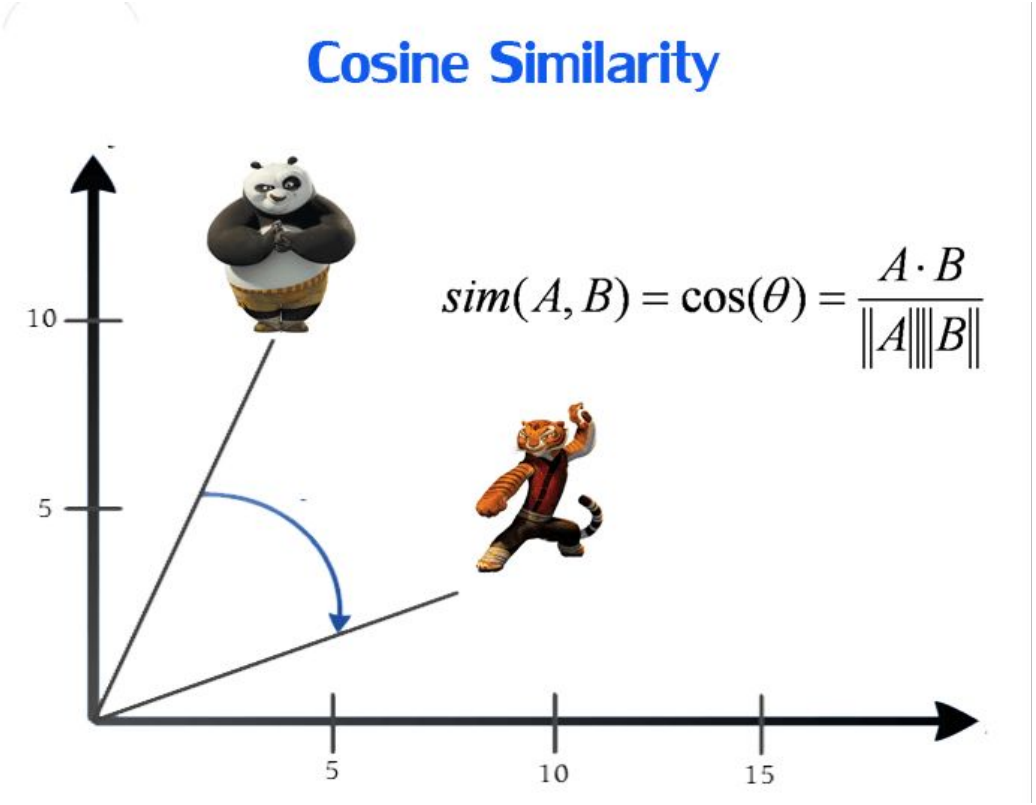

- надо найти способ превратить слова в вектора так, чтобы они отражали **контекст**
- найти расстояние между этими векторами одним из способов

Источник картинки.

Как сделать из слов вектора?

Итак, основная идея — **учитывать контекст**. Но как? Про это есть большая наука.

Самый простой-наивный метод — **счётный**. Идея: для каждого слова возьмём ближайшие в некотором окне (например, -5 +5). Сделаем такой же мешок слов, как делали для документов (CountVectorizer, TfidfVectorizer). Можно делать “скользящее окно”.

Плюсы: легко и быстро.

Минусы: для большого корпуса — очень большие вектора.

Word2vec

В двух словах, Word2Vec — это метод строить гораздо более компактные эмбеддинги с помощью нейросетей.

Методы:

- CBOW (Common Bag Of Words)
- skipgram

CBOW (common bag of words)

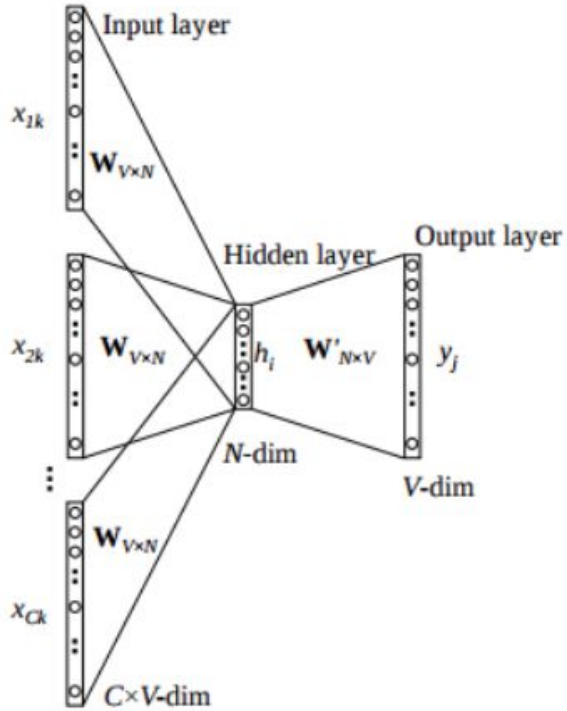

Источник картинки

Метод CBOW пытается **предсказать слово по его контексту**. Он берёт каждое слово из контекста слова Y и пытается по нему предсказать слово Y.

skipgram

skipgram, в отличие от CBOW, пытается предсказывать контекст по слову.

- **Skip Gram** хорошо работает с маленьким объёмом данных и **лучше представляет редкие слова**
- **CBOW** работает быстрее и **лучше представляет наиболее частые слова**

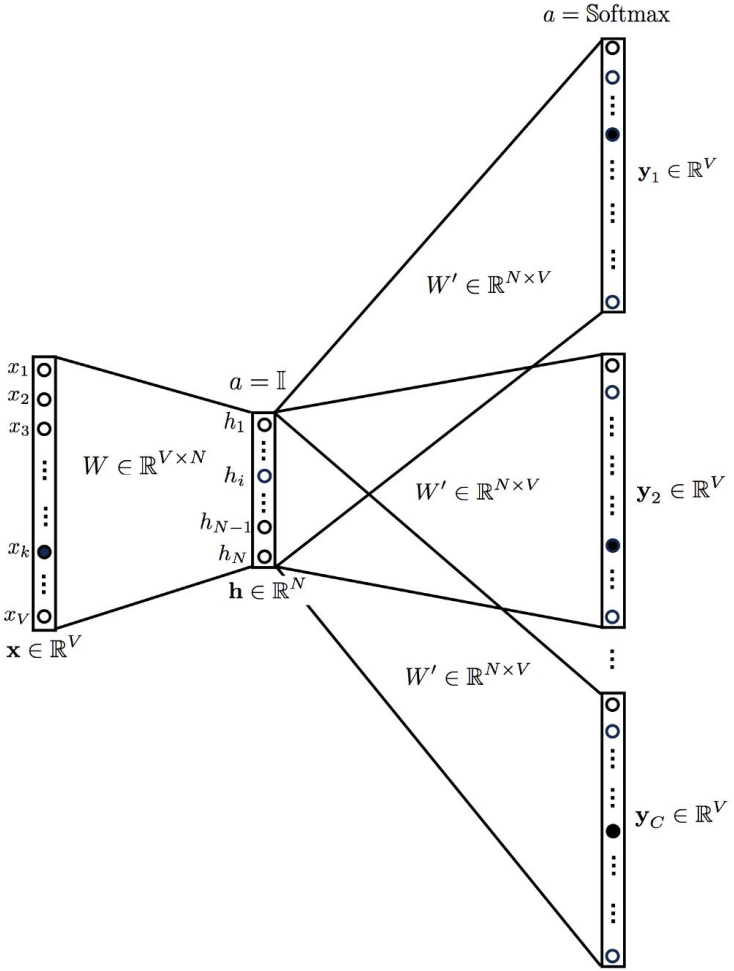

Веб-интерфейсы и ресурсы про word2vec

rusvectores — для русского

tutorial по word2vec — для английского

хорошее объяснение про word2vec и fasttext (англ)

word2vec tutorial на kaggle

Fasttext

Fasttext — почтиии то же самое, что и word2vec, но работает на уровне меньше, чем слово.

Идея такая: разбиваем каждое слово на *символьные нграммы*. Например, так: **apple → app**, **ppl**, **ple**

Обучаем нейросетку так, чтобы получить эмбеддинги этих кусочков. Финальный эмбеддинг слова — сумма эмбеддингов его кусочков.

В чём профит? Умеем представлять даже слова, которых не было в корпусе!

GloVe

- идея окна-контекста, как в Word2Vec
- вместо слов, предсказываем соотношения вероятностей совстречаемости слов

$$F(w_i, w_j, \tilde{w}_k) \approx \frac{P_{ij}}{P_{jk}}$$

$$P_{ij} = \frac{\text{number of times j appeared in context of i}}{\text{number of words that appeared in context of i}}$$

- тем самым, используем “глобальную информацию” о совстречаемости по всему корпусу

Где взять готовые эмбеддинги

Можно обучить свои эмбеддинги. Но это долго и не всегда нужно. Есть ли уже обученные эмбеддинги? Конечно!

Rusvectores! (для русских слов)

AdaGram: Adaptive Skip-Gram

Гитхаб, статья.

Мотивация: слова многозначны.

Решение: получать не один эмбеддинг для слова, а несколько разных эмбеддингов, соответствующих разным группам контекстов.

Пример:

apple (1) — `("almond",1,0.70396507f0)  ("cherry",2,0.69193166f0)  ("plum",1,0.690269f0)`

apple (2) — `("macintosh",1,0.79053026f0)  ("iifx",1,0.71349466f0)  ("iigs",1,0.7030192f0)`

Как заэмбеддить текст

Простые способы

- сумма эмбеддингов слов
  - информация о важности теряется
- сумма с tfidf весами
  - лучше, но вычислительно сложнее и не всегда работает
- ключевые слова, термины
  - например, взять только их
  - или придать им больший вес

WMD

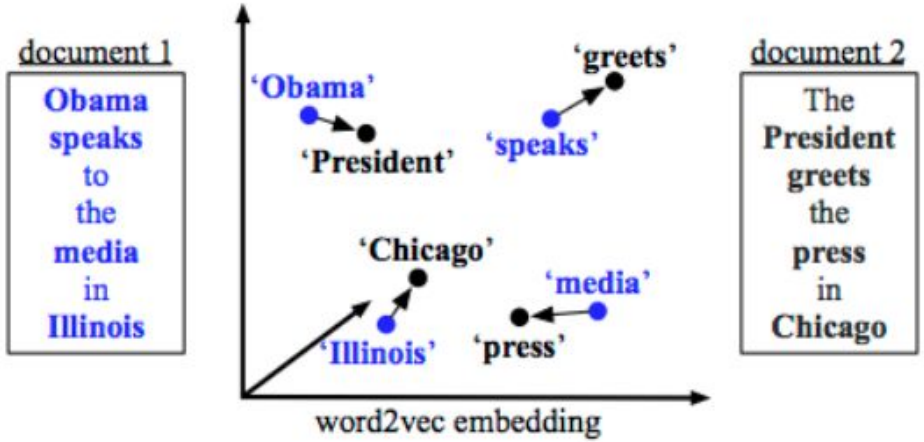

Figure 1. An illustration of the *word mover's distance*. All non-stop words (***bold***) of both documents are embedded into a *word2vec* space. The distance between the two documents is the minimum cumulative distance that all words in document 1 need to travel to exactly match document 2. (Best viewed in color.)

Расстояние между документами — сумма расстояний между ближайшими словами.

Ресурсы

Почитать

- Activation Functions in Neural Networks
- Neural networks and back-propagation explained in a simple way
- Introduction to Word Embedding and Word2Vec
- Word2Vec and FastText Word Embedding with Gensim
- про WMD

Посмотреть (про нейросети)

Отличная серия видео про нейросети понятным языком:

- But what *is* a Neural Network
- Understanding Gradient Descent
- What backpropagation is really doing?
- Math for backpropagation

Livecoding a NN library (на странноватом новом питоне).