LSTM и генерация текста

Маша Шеянова, masha.shejanova@gmail.com

RNN, LSTM

Вспомним обычную полносвязную нейросеть

x — входные данные (признаки); W — веса

$h_1 = f_1(W_1 * x + b_1)$

$h_2 = f_2(W_2 * h_1 + b_2)$

$y\_pred = f_3(W_3 * h_2 + b_3)$

$y\_pred = f_3(W_3 * f_2(W_2 * h_1 + b_2) + b_3)$

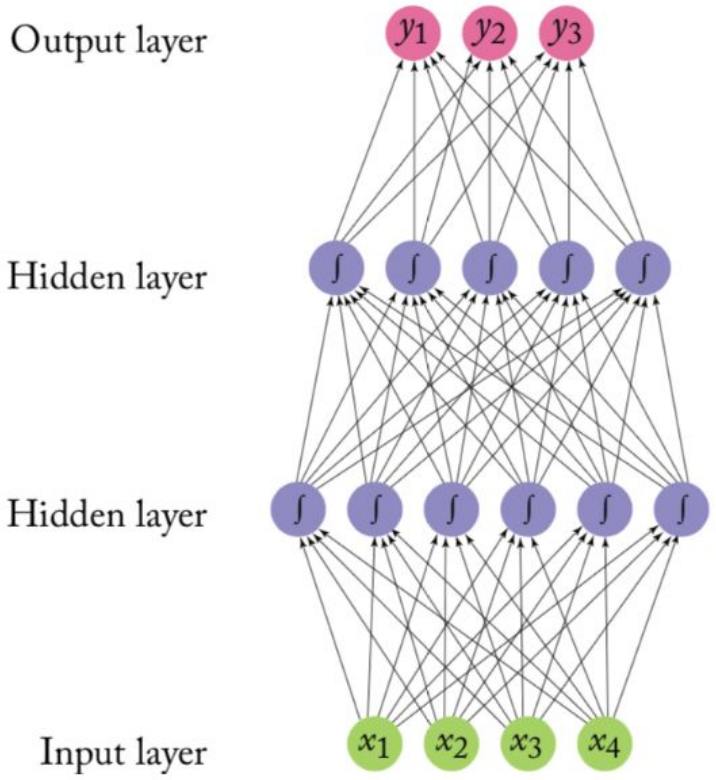

RNN (Recurrent Neural Network)

- в обычной нейросети, работая с отдельными словами, мы будем каждый раз подавать ей эмбеддинг (вектор) конкретного слова
- но работая с каждым словом в тексте, **мы хотим знать контекст**
- можно конкатенировать вектор текущего и предыдущего слова, но одного мало, а все слова в предложении — это слишком
- решение: **кодировать одним вектором весь предыдущий контекст**

Как? На каждом шаге нейросеть получает **вектор текущего слова** и **вектор выдачи нейросети** на предыдущем шаге. Конкатенирует их, и дальше работает как обычная нейросеть.

RNN

В отличие от обычной нейросети, они получают на вход не только данные, но и выход предыдущей клетки RNN.

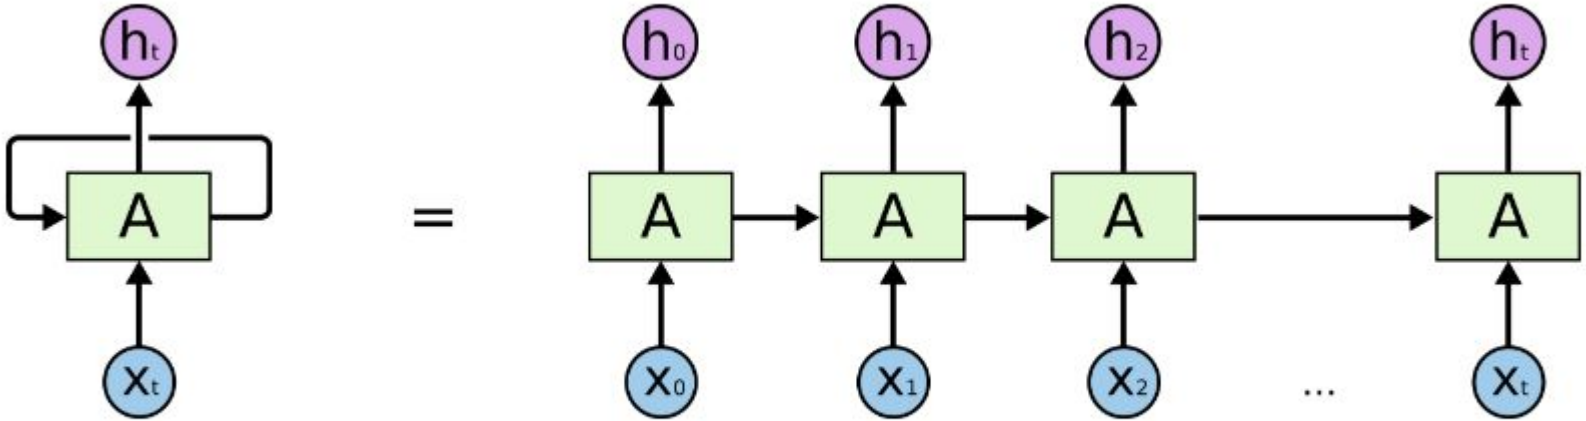

An unrolled recurrent neural network.

LSTM (Long Short Term Memory)

Проблемы с простой RNN:

- важная контекстная информация слишком быстро затирается новой
- с другой стороны, нет механизма, чтобы забывать ненужную информацию (например, забыть предыдущее предложение)

Решение — **два** контекстных вектора:

- долговременной памяти (слабо изменяется от клетки к клетке)
- кратковременной памяти (выдача предыдущей клетки)

Вектор долговременной памяти

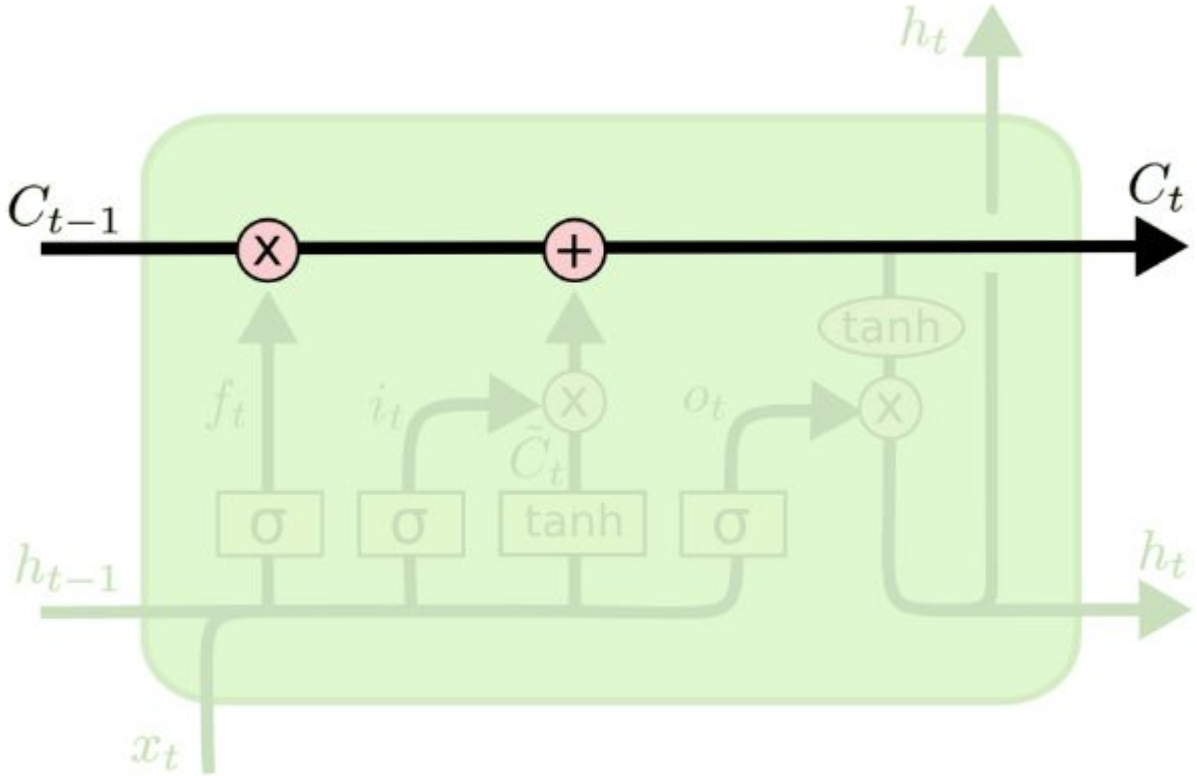

Выбираем, что “забыть”

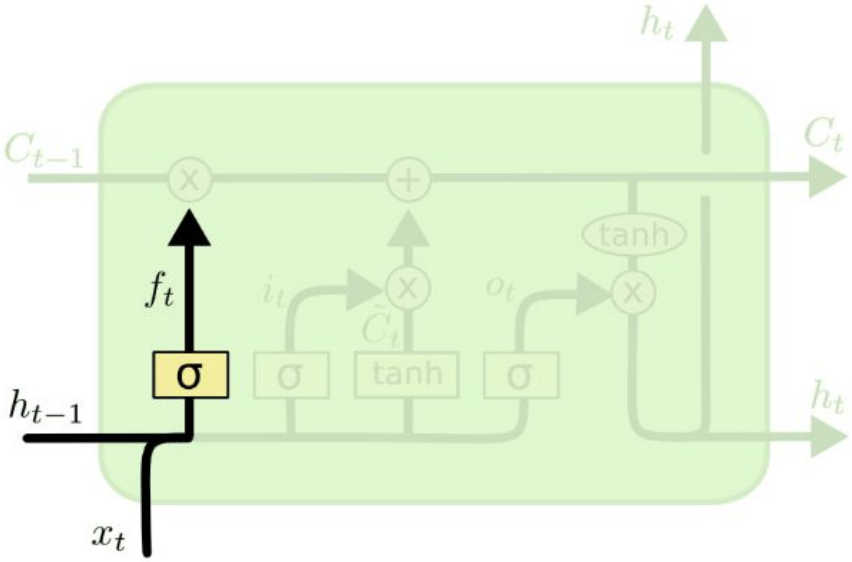

$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] \; + \; b_f\right)$$

Запоминаем новое

- i_t — выбираем, что запомнить
- $\tilde{C}_t$ — то, что можно будет запомнить

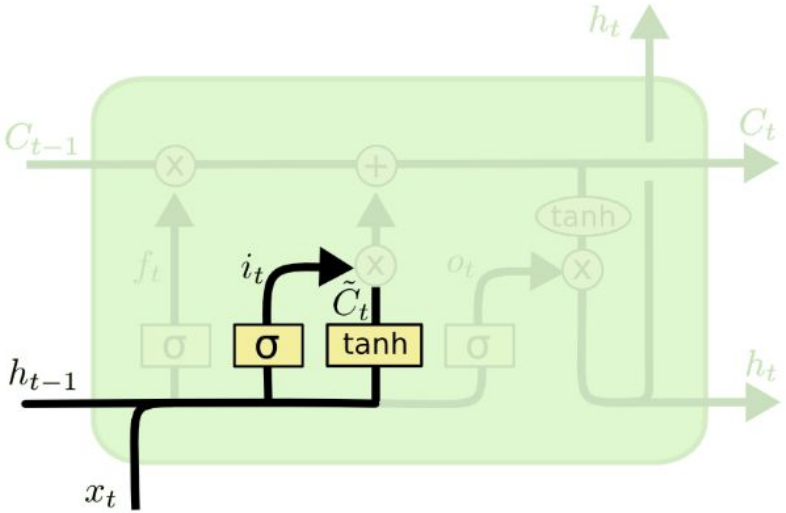

$$i_t = \sigma\left(W_i \cdot [h_{t-1}, x_t] \; + \; b_i\right)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] \; + \; b_C)$$

Обновляем долговременную память

(и больше не трогаем)

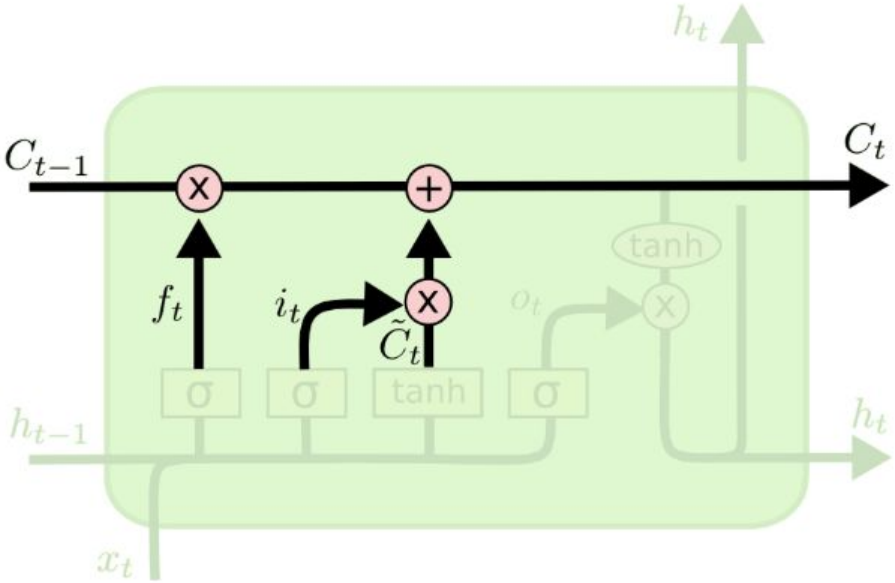

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

Получаем результат для текущего шага

выход нейросети == кратковременная память

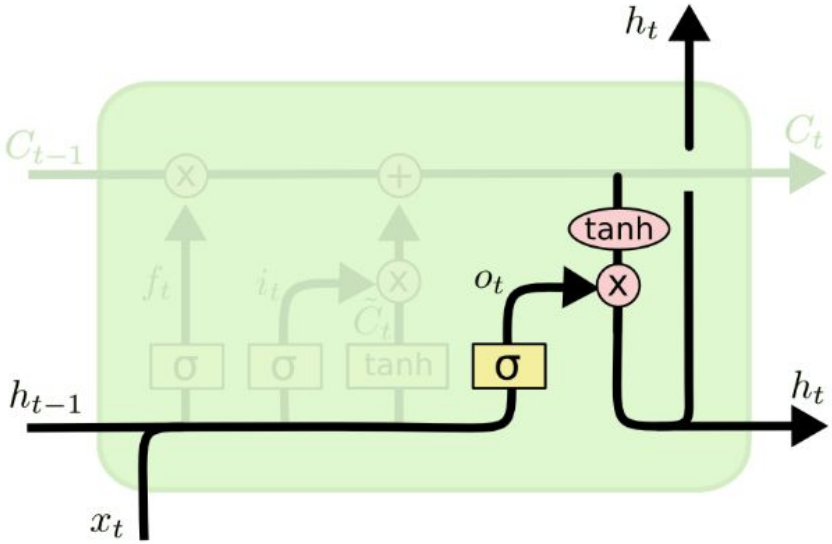

$$o_t = \sigma\left(W_o\left[h_{t-1}, x_t\right] + b_o\right)$$

$$h_t = o_t * \tanh\left(C_t\right)$$

полная LSTM клетка

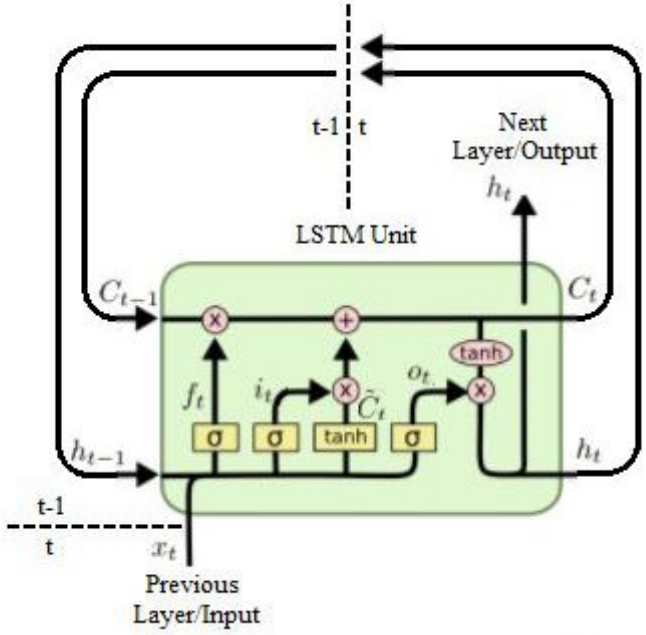

$$f_t = \sigma\left(W_f \cdot [h_{t-1}, x_t] \; + \; b_f\right)$$
$$i_t = \sigma\left(W_i \cdot [h_{t-1}, x_t] \; + \; b_i\right)$$
$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] \; + \; b_C)$$
$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$
$$o_t = \sigma\left(W_o \; [h_{t-1}, x_t] \; + \; b_o\right)$$
$$h_t = o_t * \tanh\left(C_t\right)$$

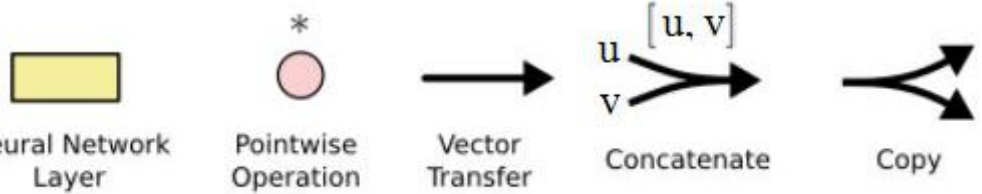

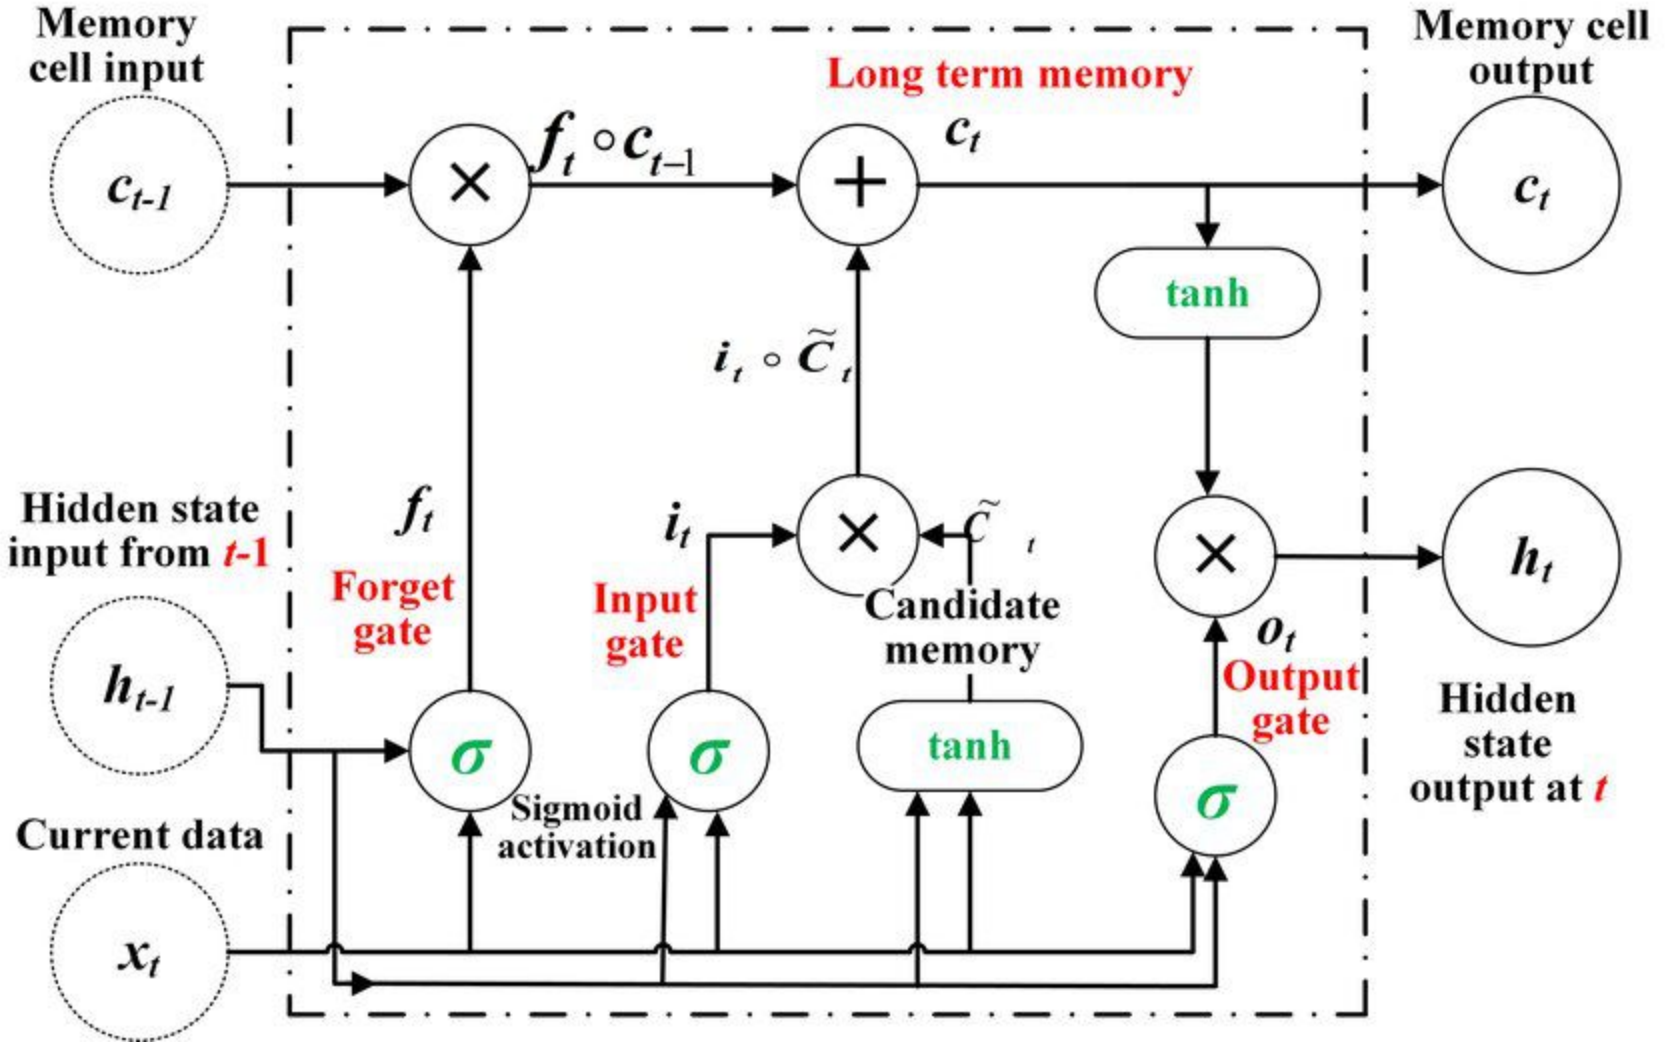
Memory cell input
c_{t-1}
$f_t \circ c_{t-1}$
Long term memory
c_t
Memory cell output
c_t
tanh
$i_t \circ \tilde{C}_t$
Hidden state input from t-1
h_{t-1}
f_t
Forget gate
i_t
Input gate
$\tilde{C}_t$
Candidate memory
o_t
Output gate
h_t
Hidden state output at t
Current data
x_t
σ
Sigmoid activation
σ
tanh
σ

Bi-LSTM (Bidirectional LSTM)

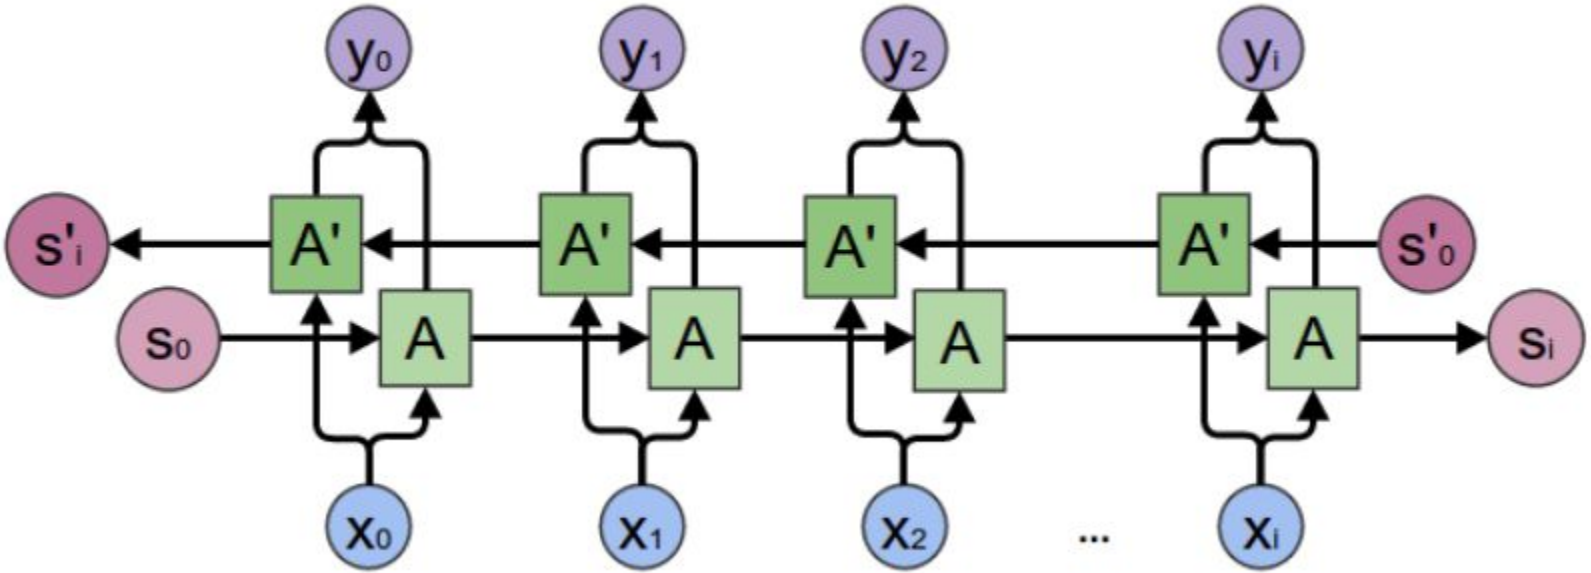

Языковые модели

Что умеет языковая модель

- предсказать самое вероятное следующее слово
  - поезд прибыл на _____
- в более общем случае, дать распределение вероятностей для следующего слова
  - поезд прибыл на ... (вокзал: 0.5; юг: 0.1; север: 0.1, ...)
- сравнить вероятности последовательностей
  - поезд прибыл на вокзал
  - поезд прибыл на отдых

Приложения

Выбрать лучший вариант среди возможных:

- спеллчекинг
- распознавание речи
- распознавание символов
- фарзовый машинный перевод

Предложить хорошее продолжение

- автодополнение
- генерация текста

Вероятность последовательности

Пусть $w_{1:n} = w_1, \ldots, w_m$ – последовательность слов.

Точная оценка вероятности этой последовательности — **цепное правило**:

$$P(X_1, ..., X_n) = P(X_1)P(X_2|X_1)...P(X_n|X_1, ..., X_{n-1}))$$

Вероятность следующего слова:

$$P(X_n|X_1, ..., X_{n-1})) = \frac{P(X_1, ..., X_n)}{P(X_1, ..., X_{n-1}))}$$

Но оценить $P(w_k|w_{1:k-1})$ не легче!

Цепи Маркова

Мы пользуемся **марковским предположением**:

текущее состояние зависит лишь от конечного числа предыдущих состояний

Иными словами:

$$P(w_i|w_1 \ldots w_{i1}) \approx P(w_i|w_{in} +_1 \ldots w_{i1})$$

Цепи Маркова

- направленный граф
- вершины — “состояния” (в нашем случае, слова или символы)
- на рёбрах — вероятность перехода из одного состояния в другое

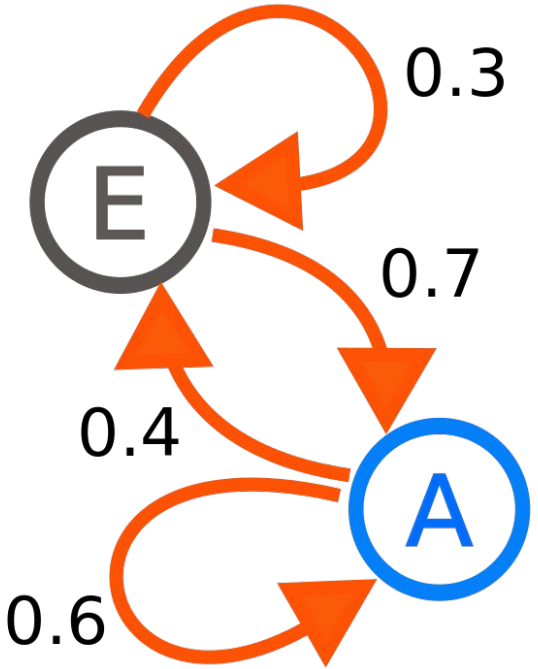

Цепи Маркова на N-граммах

Переходим к n-грамам: $P(w_{i+1}|w_{1:i}) \approx P(w_{i+1}|w_{i-n:i})$, то есть, учитываем $n-1$ предыдущее слово. Т.е. используем Марковские допущения о длине запоминаемой цепочки.

Модель

- униграм: $P(w_k)$
- биграм: $P(w_k|w_{k-1})$
- триграм: $P(w_k|w_{k-1}w_{k-2})$

От цепей Маркова к RNN

Ограничение марковских цепей на N-граммах:

- маленькое N — слишком несвязная
  - я приехал наконец на питоне писать приятно
- большое N — слишком сильно подстраивается под обучающий корпус

Если данных много, лучше обучить RNN.

- можно учить предсказывать следующее слово
- можно считать косинусное расстояние до следующего слова
- а в генерации текста можно ...

Генерация текста (NLG)

Зачем?

- развлечение
- развлечение
- ещё раз развлечение
- генерация сюжетов в играх (тоже развлечение)
- чат-бот для психологической помощи?

Во-первых, это весело!

Ветхий Алгоритм @alg_testament · Jul 24

эта процедура должна работать не так, отец мой, отец мой, не бесчести имени Бога твоего.

Translate Tweet

1 33 94

Ветхий Алгоритм @alg_testament · Jul 22

Сигналы, генерируемые терминалом, возникают, когда пользователь входит в дом Господень

Translate Tweet

39 103

Ветхий Алгоритм @alg_testament · Jul 22

И поставлю Себе священника верного; он будет обладать правами суперпользователя.

Translate Tweet

1 82 217

Как?

- самое простое: марковская цепь
- поинтереснее: RNN / LSTM с предсказанием следующего слова
- ещё интереснее: RNN → GAN

GAN (generative adversarial network)

Две нейросети: “генератор” и “дискриминатор”.

- генератор порождает какой-то текст (изначально случайный)
- дискриминатор получает:
  - либо сгенерированный текст
  - либо из “человеческий” (из корпуса)
- … и пытается определить какой ему текст дали (бинарная классификация)
- функция потерь дискриминатора — отличил ли истинный от “подделки”
- функция потерь генератора — “получилось ли обмануть дискриминатор”
- обучаются обе, но для генерации нужна первая

GAN

Вообще, GANы пришли из картинок, где достигли впечатляющих результатов.

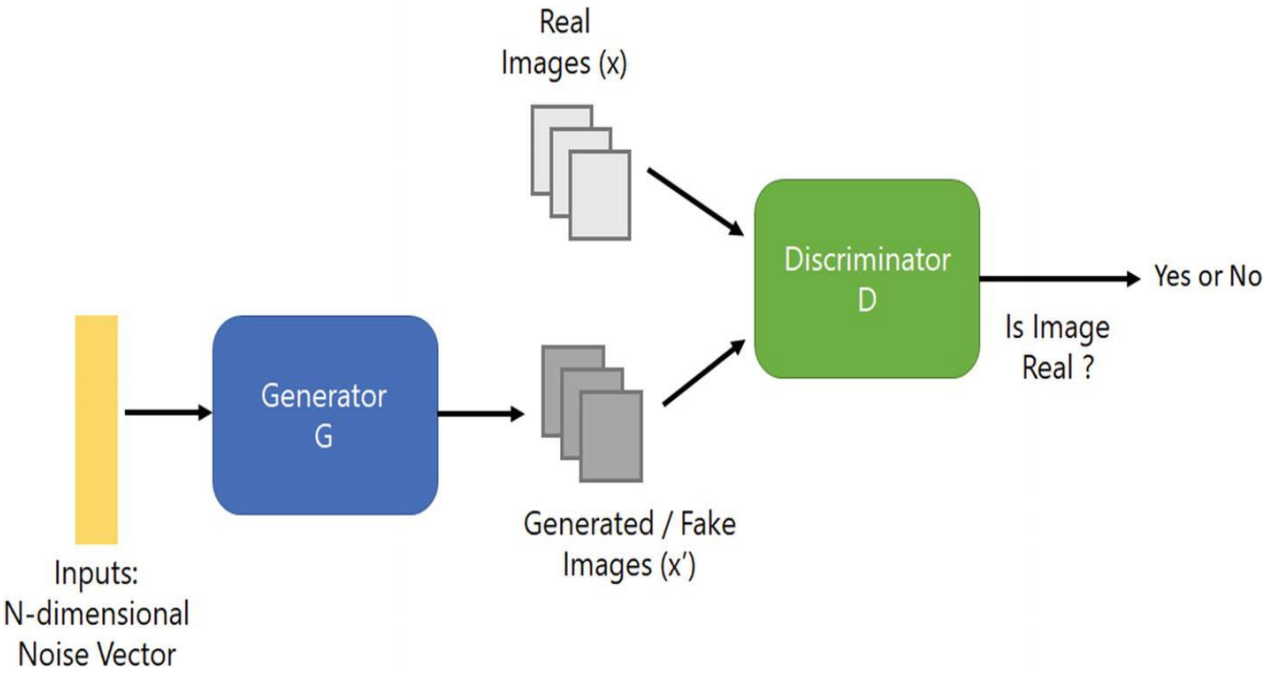

Что дальше?

seq2seq

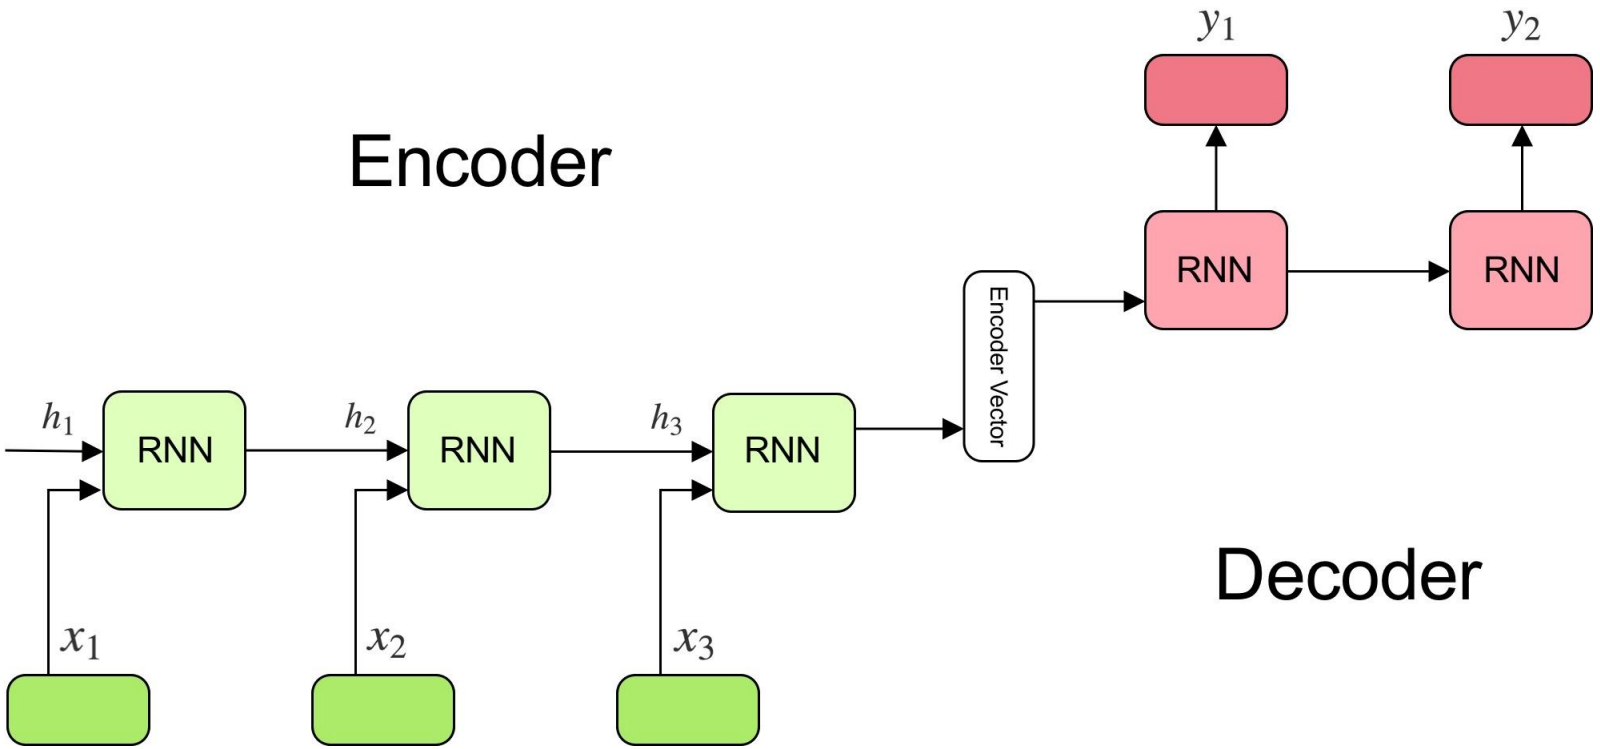
Encoder
Decoder
RNN
RNN
RNN
RNN
RNN
Encoder Vector
h_1
h_2
h_3
x_1
x_2
x_3
y_1
y_2

seq2seq + attention

Transformers